

تحليل شامل لخوارزمية Watershed في معالجة الصور من النظري + العملي باستخدام OpenCV

إشراف م : سميرة الشيبية

إعداد : طارق فضل العمري

```
import cv2
import numpy as np
import matplotlib.pyplot as plt

# اقرأ الصورة
img = cv2.imread('images/water_coins.jpg')
gray = cv2.cvtColor(img, cv2.COLOR_BGR2GRAY)

# Thresholding الخطوة 1: عزل العملات عن الخلفية باستخدام
ret, thresh = cv2.threshold(gray, 0, 255, cv2.THRESH_BINARY_INV
+ cv2.THRESH_OTSU)

# Opening الخطوة 2: إزالة التشويش باستخدام
kernel = np.ones((3, 3), np.uint8)
opening = cv2.morphologyEx(thresh, cv2.MORPH_OPEN, kernel,
iterations=2)

# الخطوة 3: تحديد "الخلفية المؤكدة" عن طريق تمديد المساحة البيضاء
sure_bg = cv2.dilate(opening, kernel, iterations=3)

# الخطوة 4: تحديد "الأجسام المؤكدة" عن طريق حساب المسافة من الحواف
```

```

dist_transform = cv2.distanceTransform(opening, cv2.DIST_L2, 5)
ret, sure_fg = cv2.threshold(dist_transform, 0.7 *
dist_transform.max(), 255, 0)
sure_fg = np.uint8(sure_fg)


# الخطوة 5: تحديد "المنطقة المجهولة" (الحدود الفاصلة)
unknown = cv2.subtract(sure_bg, sure_fg)

# الخطوة 6: ترقيم كل منطقة جسم مؤكدة برقم فريد
ret, markers = cv2.connectedComponents(sure_fg)
markers = markers + 1
markers[unknown == 255] = 0

# Watershed الخطوة 7: تطبيق خوارزمية
markers = cv2.watershed(img, markers)
img[markers == -1] = [255, 0, 0] # تلوين الحدود باللون الأحمر

# عرض الصورة النهائية بعد التقسيم
plt.imshow(cv2.cvtColor(img, cv2.COLOR_BGR2RGB))
plt.title("Watershed Segmentation")
plt.show()

```



القسم الأول: مقدمة إلى تقسيم الصور بخوارزمية Watershed: التشبيه الطبوغرافي

تُعد خوارزمية Watershed واحدة من أقوى تقنيات تقسيم الصور (Image Segmentation) وأكثرها بديهية، وهي مستوحاة من مجال الجغرافيا والطبوغرافيا. يعتمد نجاح هذه الخوارزمية على قدرتها على تحويل مشكلة تقسيم الكائنات في صورة رقمية إلى مشكلة طبوغرافية يمكن حلها من خلال محاكاة عملية فيضان طبيعية. لفهم آلية عملها، يجب أولاً استيعاب التشبيه الأساسي الذي تقوم عليه.

1.1 المبدأ الأساسي: الصورة كخريطة طبوغرافية

يمكن المفهوم الجوهرى لخوارزمية Watershed في أنها تتعامل مع صورة ذات تدرج رمادي (grayscale) كما لو كانت منظرًا طبيعيًا أو تضاريس طبوغرافية ثلاثية الأبعاد.¹ في هذا التشبيه، لا تمثل قيم البكسلات مجرد ألوان أو درجات من السطوع، بل تُترجم إلى "ارتفاعات" في هذا المشهد المتخيل.³ البكسلات ذات الكثافة العالية (الأكثر سطوعًا) تُعتبر "قممًا" أو "تلالًا" عالية، بينما البكسلات ذات الكثافة المنخفضة (الأكثر قتامة) تمثل "وديانًا" أو "أحواضًا" منخفضة.⁵

ومع ذلك، من النادر تطبيق الخوارزمية مباشرة على الصورة الأصلية. السبب في ذلك هو أن كثافة البكسل في الصورة الأصلية قد تحتوي على العديد من النقاط الدنيا المحلية (local minima) بسبب نسيج الكائن (texture) أو الضوضاء، مما قد يؤدي إلى نتائج فوضوية. بدلاً من ذلك، يتم تطبيق الخوارزمية بشكل شبه دائم على "صورة التدرج" (gradient image) للصورة الأصلية.¹ صورة التدرج هي تمثيل رياضي يُبرز المناطق التي تحدث فيها تغيرات حادة في كثافة البكسل. في هذا المشهد الجديد، تتغير دلالة الارتفاعات بشكل جذري:

- القمم والتلال (قيم تدرج عالية): تمثل الآن حواف الكائنات، حيث يكون التباين بين البكسلات المتجاورة في أعلى مستوياته.⁸
- الوديان والأحواض (قيم تدرج منخفضة): تمثل المناطق المتجانسة داخل الكائنات أو في الخلفية، حيث تكون التغيرات في كثافة البكسل طفيفة.⁹

هذا التحول في المنظور بالغ الأهمية، فهو يعيد صياغة المشكلة من "تقسيم الصورة بناءً على كثافتها" إلى "إيجاد الحواجز (الحواف) التي تفصل بين المناطق المتجانسة (داخل الكائنات)". هذا يجعل صورة التدرج هي المشهد الطبوغرافي الحقيقي الذي تعمل عليه الخوارزمية لتحقيق تقسيم هادف.

1.2 المصطلحات الأساسية: الأحواض، خطوط التقسيم، والفيضان

لفهم عملية المحاكاة، لا بد من تعريف المصطلحات الطبوغرافية الأساسية في سياق معالجة الصور:

- أحواض التجميع (Catchment Basins): في الجغرافيا، حوض التجميع هو المنطقة التي تتدفق منها مياه الأمطار لتتجمع في نقطة مشتركة. في سياق الخوارزمية، يمثل حوض التجميع مجموعة من البكسلات التي إذا سقطت عليها "قطرة ماء" افتراضية، فإنها ستندفق "نزولاً" على طول مسار الانحدار الأشد لتصل إلى نفس النقطة الدنيا المحلية.¹ كل حوض تجميع سيشكل في النهاية

- منطقة أو "جزء" (segment) واحدًا في الصورة المقسمة النهائية.¹
 - خطوط تقسيم المياه (**Watershed Lines/Ridges**): هذه هي القمم أو التلال التي تفصل بين أحواض التجميع المختلفة. إنها النقاط التي تكون على ارتفاع متساوٍ من حوضين أو أكثر، حيث تلتقي "المياه" المتدفقة من مصادر مختلفة.³ عند هذه النقاط، يتم بناء "سدود" أو "حواجز" افتراضية لمنع اندماج المياه.¹¹ هذه الخطوط تمثل الحدود النهائية بين الكائنات المقسمة.¹
 - محاكاة الفيضان (**Flooding Simulation**): الطريقة الأكثر شيوعًا لتصوير الخوارزمية هي من خلال محاكاة الفيضان.⁷ تبدأ العملية بالخطوات التالية:
 1. تحديد جميع النقاط الدنيا المحلية في المشهد الطبوغرافي (صورة التدرج).
 2. يتم "نقّب" كل نقطة دنيا، مما يسمح للماء بالبدء في التدفق منها.
 3. يتم غمر المشهد بأكمله بالماء بشكل تدريجي ومتساوٍ، بدءًا من أدنى النقاط الدنيا ارتفاعًا.¹
 4. مع ارتفاع منسوب المياه، تبدأ الأحواض الفردية في الامتلاء والتوسع.
 5. عندما توشك المياه القادمة من حوضين مختلفين على الالتقاء، يتم بناء "سد" (خط تقسيم المياه) على طول نقاط الالتقاء لمنعها من الاندماج.¹⁴
 6. تستمر هذه العملية حتى يتم غمر المشهد بأكمله، وتكون السدود التي تم بناؤها هي التي تشكل حدود التقسيم النهائية.²
- هذا التشبيه القوي لا يوضح آلية العمل فحسب، بل يكشف أيضًا عن نقطة ضعف كامنة في النهج التقليدي، والتي سيتم تناولها في القسم التالي.

القسم الثاني: تحدي التقسيم المفرط (Over-segmentation) في خوارزمية Watershed التقليدية

على الرغم من أناقة مفهومها، فإن التطبيق المباشر لخوارزمية Watershed التقليدية على الصور الواقعية غالبًا ما يؤدي إلى نتيجة غير مرغوب فيها تُعرف باسم "التقسيم المفرط" (Over-segmentation). هذه الظاهرة هي العائق الرئيسي الذي حال دون استخدام الخوارزمية على نطاق واسع في شكلها الأصلي، وفهم أسبابها أمر بالغ الأهمية لفهم الحاجة إلى النهج الموجه بالعلامات الذي سيتم شرحه.

2.1 السبب الجذري للمشكلة

ينبع التقسيم المفرط مباشرة من المبدأ الأساسي للخوارزمية: حساسيتها الشديدة لكل نقطة دنيا محلية (local minimum) في المشهد الطبوغرافي (صورة التدرج).² في الخوارزمية التقليدية، تُعامل كل نقطة دنيا محلية، بغض النظر عن عمقها أو أهميتها، على أنها "مصدر" مستقل لعملية الفيضان، وبالتالي تؤسس حوض تجميع خاص بها.¹⁵

في الصور الحقيقية، حتى بعد حساب التدرج، يكون المشهد الطبوغرافي بعيدًا عن المثالية. عوامل مثل:

- الضوضاء (**Noise**): التغيرات العشوائية الطفيفة في قيم البكسل، حتى لو كانت غير مرئية للعين البشرية، تخلق عددًا كبيرًا من النقاط الدنيا المحلية الصغيرة والضحلة.¹⁴

- نسيج الكائن (**Texture**): الأسطح غير الملساء تمامًا للكائنات تحتوي على تفاصيل دقيقة وتغيرات طفيفة في الكثافة، والتي تُترجم إلى وديان وتلال صغيرة في صورة التدرج.
 - التدرجات غير المهمة: أي تباين طفيف في الإضاءة أو السطح يمكن أن يخلق نقاطاً دنيا محلية لا تمثل حدوداً حقيقية للكائنات.
- كل عامل من هذه العوامل يساهم في تلوين المشهد الطبوغرافي بآلاف النقاط الدنيا المحلية غير المرغوب فيها.

2.2 عواقب التقسيم المفرط

عندما تبدأ خوارزمية Watershed التقليدية عملية الفيضان من كل هذه النقاط الدنيا، تكون النتيجة كارثية من منظور التقسيم الهادف. بدلاً من الحصول على منطقة واحدة لكل كائن، يتم تقسيم الصورة إلى عدد هائل من المناطق الصغيرة جدًا وغير المجدية.⁷ على سبيل المثال، عند محاولة تقسيم صورة تحتوي على خلايا متجاورة، قد يتم تقسيم خلية واحدة إلى عشرات أو حتى مئات الأجزاء الصغيرة، كل جزء يتوافق مع نقطة دنيا محلية ناتجة عن تفاصيل داخل نواة الخلية أو ضوضاء في الصورة.

يمكن تصور ذلك في مثال تقسيم حبيبات الفولاذ المجهرية.⁴ قد تبدو الحبيبات متجانسة للعين، لكن صورتها الرقمية ستحتوي على اختلافات طفيفة في الكثافة. ستؤدي الخوارزمية التقليدية إلى إنشاء "حوض" لكل اختلاف طفيف، مما ينتج عنه فسيفاء من المناطق الصغيرة داخل كل حبة فولاذ، بدلاً من تحديد حدود الحبة نفسها.

هذه المشكلة تجعل الخوارزمية في شكلها الخام غير قابلة للاستخدام عمليًا لمعظم مهام تقسيم الصور، حيث أن الهدف هو استخلاص كائنات كاملة وذات معنى، وليس مجرد خريطة مفصلة لكل التغيرات الطفيفة في كثافة الصورة.⁷ من منظور خوارزمي بحت، لا يمكن اعتبار هذا "خطأ" في الخوارزمية؛ فهي تؤدي وظيفتها بأمانة تامة، حيث تقوم بتقسيم المشهد الطبوغرافي بناءً على جميع نقاطه الدنيا. المشكلة الحقيقية لا تكمن في آلية الفيضان نفسها، بل في "المشهد" الذي يتم إعطاؤه لها، فهو معقد وملئ بالضوضاء بشكل يفوق الهدف الدلالي (semantic goal) المطلوب. هذا يعيد صياغة المشكلة: الحل ليس "إصلاح" خوارزمية Watershed، بل "تبسيط المشهد الطبوغرافي" قبل تطبيقها. وهذا يقود مباشرة إلى ضرورة النهج الموجه بالعلامات.

القسم الثالث: الحل المتقدم: خوارزمية Watershed الموجهة بالعلامات (Marker-Controlled)

لمواجهة التحدي الحاسم المتمثل في التقسيم المفرط، تم تطوير نهج أكثر تطوراً وقوة يُعرف باسم خوارزمية Watershed الموجهة بالعلامات (Marker-Controlled أو Seeded Watershed). هذا النهج لا يغير من آلية الفيضان الأساسية، بل يغير بشكل جذري من أين يُسمح للفيضان بالبدء، مما يمنح المستخدم تحكماً دقيقاً في عملية التقسيم ويحول الخوارزمية من أداة نظرية إلى تقنية عملية وفعالة للغاية.

3.1 مبدأ التحكم بالعلامات

الفكرة الأساسية وراء النهج الموجه بالعلامات هي إدخال "معلومات مسبقة" (prior information) في الخوارزمية من خلال تحديد نقاط بداية الفيضان بشكل صريح.⁵ هذه النقاط، التي تسمى "العلامات" (Markers)، هي مناطق من البكسلات يحددها المستخدم (أو تحددها خوارزمية أخرى) على أنها تنتمي بالتأكيد إلى كائن معين أو إلى الخلفية.¹⁴

بدلاً من السماح للفيضان بالبدء تلقائياً من كل نقطة دنيا محلية موجودة في صورة التدرج، يتم إجبار عملية الفيضان على البدء فقط وحصرها من مواقع العلامات المحددة مسبقاً.¹³ هذا الإجراء البسيط في مفهومه له تأثير عميق: فهو يحل مشكلة التقسيم المفرط من جذورها عن طريق تقليص عدد أحواض التجميع الأولية بشكل كبير، ليقتصر فقط على عدد العلامات التي تم توفيرها.¹⁷ إذا تم وضع علامة واحدة داخل كل كائن مراد تقسيمه، فستنتج الخوارزمية منطقة واحدة فقط لكل كائن.

3.2 تحديد المناطق الثلاث الرئيسية (الفلسفة وراء الكود)

يعتمد التنفيذ العملي لخوارزمية Watershed الموجهة بالعلامات، خاصة في مكتبات مثل OpenCV، على تقسيم الصورة بشكل منهجي إلى ثلاث فئات متميزة قبل تشغيل الخوارزمية. هذه الفلسفة هي حجر الزاوية في خط أنابيب المعالجة المسبقة بأكمله:¹⁴

1. المقدمة المؤكدة (**Sure Foreground**): هي مجموعة من البكسلات التي نحن على يقين تام بأنها تقع داخل الكائنات التي نرغب في تقسيمها. هذه المناطق تمثل "قلب" أو "نواة" كل كائن. على سبيل المثال، في صورة عملات معدنية متلامسة، ستكون المراكز الساطعة لكل عملة هي المقدمة المؤكدة. في صورة العلامات النهائية، يتم إعطاء كل منطقة منفصلة من المقدمة المؤكدة تسمية (label) رقمية فريدة وموجبة (على سبيل المثال، 2، 3، 4، إلخ).²⁰
2. الخلفية المؤكدة (**Sure Background**): هي مجموعة البكسلات التي نحن على يقين تام بأنها جزء من خلفية الصورة ولا تنتمي إلى أي كائن. في مثال العملات المعدنية، ستكون هذه هي المناطق البعيدة عن جميع العملات. في صورة العلامات، عادة ما يتم إعطاء كل هذه المنطقة تسمية واحدة مشتركة، مثل الرقم 1.¹⁴
3. المنطقة غير المعروفة (**Unknown Region**): هذه هي المنطقة الأكثر أهمية. إنها تمثل جميع البكسلات المتبقية التي لم يتم تصنيفها على أنها مقدمة مؤكدة أو خلفية مؤكدة. هذه المنطقة هي "المنطقة الرمادية" التي تحتوي على حدود الكائنات، والمناطق الفاصلة بين الكائنات المتلامسة، والحواف بين الكائنات والخلفية. في صورة العلامات، يتم تمييز هذه المنطقة بقيمة خاصة، وهي الصفر (0).¹⁴

هذا التقسيم المسبق يعيد تعريف مهمة الخوارزمية. بدلاً من أن يُطلب منها تقسيم الصورة بأكملها من الصفر، يُطلب منها الآن حل مشكلة أبسط وأكثر تحدياً: "لكل بكسل في المنطقة غير المعروفة (ذات القيمة 0)، حدد إلى أي منطقة معروفة (مقدمة أو خلفية) ينتمي". تصبح عملية الفيضان منافسة بين مناطق المقدمة المؤكدة والخلفية المؤكدة، حيث تتوسع كل منها في المنطقة المجهولة حتى تلتقي. خطوط تقسيم المياه (التي سنعطي القيمة -1) هي بالضبط الحدود التي تصطدم فيها هذه المناطق المتوسعة.

3.3 تعديل المشهد الطبوغرافي

من منظور رياضي، فإن عملية تحديد العلامات تعادل تعديل دالة التقسيم (صورة التدرج) بشكل مصطنع. يتم تعديل المشهد الطبوغرافي

بحيث يتم "تجويفه" أو "خفضه" بشكل كبير عند مواقع العلامات، مما يضمن أن هذه المواقع هي النقاط الدنيا الوحيدة في المشهد المعدل.⁵ جميع النقاط الدنيا المحلية الأخرى التي كانت موجودة بسبب الضوضاء أو النسيج يتم "إغراقها" أو تسويتها بشكل فعال. هذا يضمن أن الفيضان لا يمكن أن يبدأ إلا من الأماكن التي سمحنا بها صراحةً، مما يمنحنا السيطرة الكاملة على نتيجة التقسيم.

القسم الرابع: تحليل تطبيقي مفصل قائم على كود OpenCV

يمثل هذا القسم جوهر التقرير، حيث يتم الانتقال من المفاهيم النظرية إلى التطبيق العملي من خلال تحليل مفصل لخطوات التنفيذ النموذجية لخوارزمية Watershed الموجهة بالعلامات باستخدام مكتبة OpenCV في لغة Python. سيتم تفكيك العملية خطوة بخطوة، مع التركيز على الغرض من كل دالة وكيف تساهم في بناء "صورة العلامات" المثالية التي توجه الخوارزمية النهائية. المثال الكلاسيكي المستخدم لتوضيح هذه العملية هو تقسيم مجموعة من العملات المعدنية المتلاصقة.¹⁴

4.1 إعداد الصورة الأولي

تبدأ العملية بسلسلة من خطوات المعالجة المسبقة القياسية لتهيئة الصورة.

- التحميل والتحويل إلى التدرج الرمادي:

Python

```
import cv2
```

```
import numpy as np
```

```
img = cv2.imread('coins.png')
```

```
gray = cv2.cvtColor(img, cv2.COLOR_BGR2GRAY)
```

الخطوة الأولى هي تحميل الصورة باستخدام `cv2.imread()`. نظرًا لأن خوارزمية Watershed تعمل على مشهد طبوغرافي أحادي البعد (الارتفاع)، يتم تحويل الصورة الملونة (BGR) إلى صورة ذات تدرج رمادي باستخدام `cv2.cvtColor()`.²⁰

- تطبيق العتبة (Thresholding):

Python

```
ret, thresh = cv2.threshold(gray, 0, 255, cv2.THRESH_BINARY_INV + cv2.THRESH_OTSU)
```

الهدف هنا هو إنشاء صورة ثنائية (binary) تفصل الكائنات (المقدمة) عن الخلفية.

- `cv2.THRESH_BINARY_INV`: هذا الخيار يقوم بعكس عملية العتبة؛ البكسلات التي تتجاوز العتبة تصبح سوداء (0)، وتلك التي تحتها تصبح بيضاء (255). هذا مفيد لجعل الكائنات بيضاء على خلفية سوداء، وهو التنسيق القياسي للعديد من العمليات المورفولوجية.²⁰

- `cv2.THRESH_OTSU`: هذه إضافة حاسمة. بدلاً من اختيار قيمة عتبة ثابتة يدويًا، تقوم خوارزمية Otsu تلقائيًا بحساب قيمة العتبة المثلى التي تزيد من التباين بين فئتي البكسلات (المقدمة والخلفية). هذا يجعل العملية أكثر قوة وقابلية للتكيف مع

ظروف الإضاءة المختلفة دون الحاجة إلى تعديل يدوي.¹⁴

4.2 إزالة الضوضاء وتحديد الخلفية المؤكدة

الصورة الثنائية الناتجة عن العتبة غالبًا ما تحتوي على ضوضاء (نقاط بيضاء صغيرة في الخلفية). الخطوات التالية تهدف إلى تنظيف الصورة واستخدامها لتحديد منطقة الخلفية المؤكدة.

- عملية الفتح المورفولوجي (**Opening**):

Python

```
kernel = np.ones((3,3), np.uint8)
```

```
opening = cv2.morphologyEx(thresh, cv2.MORPH_OPEN, kernel, iterations=2)
```

الفتح المورفولوجي هو عملية تآكل (erosion) تليها عملية توسيع (dilation). تأثيره الأساسي هو إزالة "الضوضاء البيضاء" أو النقاط الصغيرة المعزولة من الصورة دون التأثير بشكل كبير على حجم أو شكل الكائنات الرئيسية.¹¹ تكرار العملية (iterations=2) يعزز من تأثير التنظيف.

- عملية التوسيع (**Dilation**) لتحديد الخلفية المؤكدة:

Python

```
sure_bg = cv2.dilate(opening, kernel, iterations=3)
```

بعد تنظيف الصورة، يتم تطبيق عملية التوسيع على الكائنات البيضاء. هذا يؤدي إلى زيادة حجمها قليلًا. المنطقة السوداء المتبقية بعد هذا التوسيع تكون بعيدة بشكل مؤكد عن حواف الكائنات الأصلية، وبالتالي يمكن اعتبارها بثقة "خلفية مؤكدة" (¹⁴sure_bg).

4.3 تحديد المقدمة المؤكدة باستخدام تحويل المسافة

التحدي الأكبر في تقسيم الكائنات المتلامسة هو فصلها. تحويل المسافة هو أداة قوية لتحقيق ذلك عن طريق تحديد مراكز الكائنات.

- حساب تحويل المسافة (**Distance Transform**):

Python

```
dist_transform = cv2.distanceTransform(opening, cv2.DIST_L2, 5)
```

تأخذ هذه الدالة الصورة الثنائية النظيفة (opening) كمدخل. لكل بكسل أبيض (جزء من كائن)، تحسب المسافة إلى أقرب بكسل أسود (الخلفية).²³ النتيجة (

dist_transform) هي صورة ذات تدرج رمادي حيث تكون قيم البكسلات في مراكز الكائنات هي الأعلى (الأكثر سطوعًا)

لأنها الأبعد عن الحافة، وتتناقص القيم تدريجيًا كلما اقتربنا من الحواف.⁴

- عتبة خريطة المسافة لتحديد المقدمة المؤكدة:

Python


```
ret, sure_fg = cv2.threshold(dist_transform, 0.7 * dist_transform.max(), 255, 0)
```

من خلال تطبيق عتبة على خريطة المسافة، يمكننا عزل المناطق الأكثر سطوعاً فقط. هنا، يتم أخذ 70% من أقصى قيمة مسافة كعتبة. هذا يضمن أننا نحصل فقط على "نوى" الكائنات، وهي المناطق التي يمكننا التأكد من أنها جزء من المقدمة. هذه النوى المنفصلة هي "المقدمة المؤكدة"²⁰ (sure_fg).

4.4 تحديد المنطقة المجهولة

الآن بعد أن تم تحديد المناطق المؤكدة، يمكن حساب المنطقة المجهولة ببساطة.

Python

```
sure_fg = np.uint8(sure_fg)
unknown = cv2.subtract(sure_bg, sure_fg)
```

يتم أولاً تحويل sure_fg إلى نوع بيانات 8-bit. بعد ذلك، يتم طرح صورة المقدمة المؤكدة من صورة الخلفية المؤكدة. المنطق هنا واضح: المنطقة المجهولة هي كل ما هو جزء من الخلفية الموسعة (sure_bg) ولكنه ليس جزءاً من نوى المقدمة (sure_fg). هذه هي بالضبط المناطق الحدودية التي تحتاج الخوارزمية إلى اتخاذ قرار بشأنها.¹¹

4.5 إنشاء صورة العلامات (Marker Image)

هذه هي المرحلة الحاسمة التي يتم فيها تجميع كل المعلومات السابقة في صورة واحدة ستوجه خوارزمية Watershed.

• ترقيم المكونات المتصلة:

Python

```
ret, markers = cv2.connectedComponents(sure_fg)
```

تأخذ دالة cv2.connectedComponents صورة المقدمة المؤكدة (sure_fg)، والتي تحتوي على نوى الكائنات كبقع بيضاء منفصلة. تقوم الدالة بمسح الصورة وتعيين تسمية (label) رقمية فريدة لكل بقعة منفصلة. على سبيل المثال، تحصل النواة الأولى على القيمة 1، والثانية على 2، وهكذا. يتم إعطاء الخلفية (اللون الأسود) القيمة 0 تلقائياً.²⁶

• تعديل التسميات:

Python

```
markers = markers + 1
```

هذه خطوة دقيقة ولكنها مهمة. يتم إضافة 1 إلى جميع التسميات في مصفوفة markers. هذا يحول تسميات الكائنات من (1, 2, 3, ...) إلى (2, 3, 4, ...)، ويحول تسمية الخلفية من 0 إلى 1. الغرض من ذلك هو تحرير القيمة 0 لاستخدامها في الخطوة التالية لتمثيل المنطقة المجهولة، مع ضمان أن الخلفية المؤكدة لها تسمية فريدة (1).¹⁴

- تمييز المنطقة المجهولة:

Python

```
markers[unknown == 255] = 0
```

هذه هي اللمسة الأخيرة. يتم تحديد جميع البكسلات في المنطقة المجهولة (unknown) وتعيين قيمتها في مصفوفة العلامات (markers) إلى 0. الآن، أصبحت صورة العلامات جاهزة تمامًا:

- الكائنات المراد تقسيمها لها تسميات موجبة فريدة (2, 3, ...).
- الخلفية المؤكدة لها القيمة 1.
- المناطق الحدودية التي سيتم تحديدها لها القيمة 0.

4.6 تطبيق خوارزمية Watershed وتفسير النتائج

مع وجود صورة العلامات المعدة بعناية، أصبحت الخطوة الأخيرة بسيطة.

- استدعاء الخوارزمية:

Python

```
markers = cv2.watershed(img, markers)
```

تأخذ دالة cv2.watershed مدخلين رئيسيين: الصورة الأصلية الملونة img (التي تستخدمها لحساب التدرجات وتحديد "ارتفاعات" المشهد الطبوغرافي)، وصورة العلامات markers التي أعدناها (والتي تحدد من أين تبدأ "الفيضانات").¹⁴

- تفسير المخرجات وتصورها:

Python

```
img[markers == -1] =
```

تقوم الدالة بتعديل مصفوفة markers مباشرة (in-place). البكسلات التي كانت قيمتها 0 (المنطقة المجهولة) يتم الآن تعيينها إلى تسمية أقرب منطقة (كائن أو خلفية) "غمرتها". الأهم من ذلك، أن البكسلات التي تشكل "السود" أو خطوط تقسيم المياه التي تم بناؤها بين المناطق المختلفة يتم تمييزها بقيمة خاصة وثابتة هي 1.¹¹ - يمكن استغلال هذه الخاصية بسهولة لتصوير النتائج. السطر الأخير من الكود يجد جميع البكسلات التي قيمتها -1 في مصفوفة markers ويقوم بتلوينها باللون الأحمر (``) على الصورة الأصلية، مما يرسم بوضوح حدود الكائنات التي تم فصلها بنجاح.

هذا التحليل المفصل يوضح أن خوارزمية Watershed الموجهة بالعلامات ليست مجرد استدعاء لدالة واحدة، بل هي خط أنابيب متعدد المراحل. كل مرحلة هي نتيجة منطقية للمرحلة التي تسبقها، مصممة لحل مشكلة محددة (الضوضاء، الكائنات المتلامسة) من أجل إعداد المدخلات المثالية للمرحلة التالية. فهم هذه السلسلة السببية هو مفتاح استخدام الخوارزمية وتكييفها بفعالية.

القسم الخامس: تحليل معمق للدوال الأساسية في مكتبة OpenCV

لتحقيق أقصى استفادة من خط أنابيب Watershed وتكييفه مع أنواع مختلفة من الصور، من الضروري فهم أعمق للدوال الرئيسية التي تشكل هذا الخط، والخيارات المتاحة في كل منها. هذا القسم يقدم نظرة تفصيلية على المعلمات والسلوكيات المحددة للدوال الحاسمة في OpenCV.

5.1 cv2.distanceTransform()

هذه الدالة هي قلب عملية فصل الكائنات المتلامسة. تقوم بتحويل صورة ثنائية إلى خريطة مسافة، حيث تمثل قيمة كل بكسل في المقدمة المسافة إلى أقرب بكسل في الخلفية.²³

- **distanceType** (نوع المسافة): يحدد هذا المعامل كيفية حساب المسافة، مما يؤثر على شكل خريطة المسافة الناتجة. الخيارات الأكثر شيوعاً هي:
 - **cv2.DIST_L2**: المسافة الإقليدية. هذه هي المسافة المستقيمة "كما يطير الغراب" بين نقطتين. وهي الأكثر دقة من الناحية الرياضية وتنتج خرائط مسافة دائرية الشكل للكائنات النقطية. وهي الخيار المفضل في معظم الحالات للحصول على مراكز كائنات دقيقة.
 - **cv2.DIST_L1**: مسافة مانهاتن (**City Block**). تحسب المسافة عن طريق جمع الفروق المطلقة في الإحداثيات الأفقية والرأسية (مثل التحرك في شوارع مدينة). تنتج خرائط مسافة مربعة الشكل.
 - **cv2.DIST_C**: مسافة رقعة الشطرنج (**Chessboard**). تحسب المسافة على أنها الحد الأقصى للفروق المطلقة في الإحداثيات (مثل حركة الملك في الشطرنج). تنتج أيضاً خرائط مسافة مربعة.
- **maskSize** (حجم القناع): يحدد حجم قناع التقريب المستخدم لحساب المسافة. يمكن أن يكون 3 أو 5 أو **cv2.DIST_MASK_PRECISE**. بالنسبة لـ **cv2.DIST_L2**، يوفر القناع بحجم 5 دقة أفضل من 3. **cv2.DIST_MASK_PRECISE** يوفر الحساب الأكثر دقة ولكنه أبطأ.²³ في معظم التطبيقات، يعتبر حجم القناع 5 توازناً جيداً بين الدقة والسرعة.

5.2 cv2.connectedComponentsWithStats()

هذه الدالة ضرورية لترجمة "نوى" الكائنات التي تم تحديدها في خطوة المقدمة المؤكدة إلى تسميات رقمية فريدة يمكن لخوارزمية Watershed استخدامها كعلامات.

- الفرق بين `connectedComponents` و `connectedComponentsWithStats`: توفر OpenCV دالتين متشابهتين. `cv2.connectedComponents` تُرجع فقط عدد التسميات ومصفوفة التسميات. أما `cv2.connectedComponentsWithStats`، وهي الأكثر فائدة في التطبيقات العملية، فتُرجع معلومات إحصائية إضافية لكل مكون متصل تم العثور عليه.²⁷
 - المخرجات المفصلة لـ `connectedComponentsWithStats`: تُرجع الدالة مجموعة من أربعة عناصر²⁷:
 1. `numLabels`: العدد الإجمالي للتسميات الفريدة التي تم العثور عليها (بما في ذلك الخلفية، التي تحمل التسمية 0).
 2. `labels`: مصفوفة بنفس حجم الصورة المدخلة، حيث تحتوي كل بكسل على قيمة التسمية الخاصة بالمكون الذي تنتمي إليه.
 3. `stats`: مصفوفة ثنائية الأبعاد تحتوي على إحصائيات لكل تسمية (كل صف يتوافق مع تسمية). الأعمدة تمثل:
 - `cv2.CC_STAT_LEFT`: إحداثي x للركن العلوي الأيسر من الصندوق المحيط (bounding box).
 - `cv2.CC_STAT_TOP`: إحداثي y للركن العلوي الأيسر.
 - `cv2.CC_STAT_WIDTH`: عرض الصندوق المحيط.
 - `cv2.CC_STAT_HEIGHT`: ارتفاع الصندوق المحيط.
 - `cv2.CC_STAT_AREA`: مساحة المكون بالبكسل.
 4. `centroids`: مصفوفة تحتوي على الإحداثيات (x, y) للنقطة المركزية لكل مكون.
- هذه الإحصائيات الإضافية لا تُقدر بثمن، حيث يمكن استخدامها لتصفية المكونات غير المرغوب فيها بناءً على حجمها أو شكلها قبل Watershed. تمريرها إلى خوارزمية

5.3 cv2.watershed()

- هذه هي الدالة النهائية التي تنفذ عملية التقسيم الفعلية.
- المدخلات المطلوبة: من المهم جدًا فهم أنواع البيانات التي تتوقعها الدالة لتجنب الأخطاء الشائعة:
 - **image**: يجب أن تكون صورة ملونة (أو رمادية مكررة على ثلاث قنوات) من النوع `CV_8UC3` (8-bit, 3-channel).
 - **markers**: يجب أن تكون مصفوفة أحادية القناة من النوع `CV_32S` (32-bit signed integer). يجب أن تحتوي هذه المصفوفة على التسميات التي تم إعدادها في الخطوات السابقة (0 للمنطقة المجهولة، 1 للخلفية، 2, 3, ... للكائنات).³²
 - السلوك (Behavior):
 - التعديل المباشر (**In-place modification**): تقوم الدالة بتعديل مصفوفة `markers` التي تم تمريرها إليها مباشرة. لا تُرجع مصفوفة جديدة. بعد التنفيذ، سيتم تحديث قيم البكسلات التي كانت 0 بقيم تسميات المناطق التي "غمرتها".¹¹
 - تمييز الحدود: الميزة الأكثر أهمية في المخرجات هي أن جميع البكسلات التي تم تحديدها كخطوط تقسيم للمياه (حدود) سيتم تعيين قيمتها إلى -1. هذه الخاصية هي التي تسمح بتصور نتائج التقسيم بسهولة عن طريق البحث عن هذه القيمة المحددة.¹⁴

جدول 1: ملخص دوال OpenCV الأساسية في خط أنابيب Watershed

لتوفير مرجع سريع وعملي، يلخص الجدول التالي الدوال الرئيسية ودورها المحدد في خط أنابيب Watershed.

المخرجات (Output)	المعاملات الرئيسية (Key Parameters)	الغرض في خط الأنابيب (Purpose in Pipeline)	الدالة (Function)
صورة ثنائية (الكائنات بيضاء، الخلفية سوداء).	cv2.THRESH_BINARY_INV, cv2.THRESH_OTSU	إنشاء قناع ثنائي أولي لفصل المقدمة عن الخلفية.	cv2.threshold
صورة ثنائية نظيفة مع إزالة النقاط الصغيرة.	cv2.MORPH_OPEN, kernel, iterations	إزالة الضوضاء من الصورة الثنائية.	cv2.morphologyEx
صورة ثنائية مع كائنات موسعة.	kernel, iterations	توسيع مناطق المقدمة لتحديد منطقة الخلفية المؤكدة.	cv2.dilate
صورة تدرج رمادي (خريطة مسافة).	cv2.DIST_L2, maskSize	حساب خريطة المسافة لتحديد مراكز (نوى) الكائنات.	cv2.distanceTransform
مصفوفة علامات مرقمة (نوع 32int).	connectivity (عادة 4 أو 8)	ترقيم نوى الكائنات المنفصلة لإنشاء علامات فريدة.	cv2.connectedComponents
مصفوفة علامات مقسمة (الحدود = 1-).	image (8UC3), markers (32S)	تنفيذ التقسيم الفعلي بناءً على العلامات وصورة التدرج.	cv2.watershed

القسم السادس: تطبيقات وحالات استخدام عملية خوارزمية Watershed

تجد خوارزمية Watershed الموجهة بالعلامات تطبيقات واسعة في العديد من المجالات التي تتطلب فصل الكائنات المتجاورة أو المتداخلة بدقة. قدرتها على إنتاج حدود مغلقة ومتصلة تجعلها أداة لا غنى عنها في سيناريوهات لا تكفي فيها تقنيات التقسيم الأخرى.

6.1 التصوير الطبي (Medical Imaging)

يعد التصوير الطبي أحد أكثر المجالات استفادة من خوارزمية Watershed، حيث أن تحليل الهياكل البيولوجية غالبًا ما يتضمن التعامل مع خلايا وأنسجة متكثلة.

- تقسيم الخلايا (**Cell Segmentation**): ربما يكون هذا هو التطبيق الأكثر شيوعًا وكلاسيكية. في صور المجهر، غالبًا ما تظهر الخلايا أو نوى الخلايا متلاصقة مع بعضها البعض، مما يجعل من الصعب عدّها أو قياس خصائصها الفردية. تتفوق خوارزمية Watershed في رسم خطوط فاصلة دقيقة بين هذه الخلايا المتجاورة، مما يتيح التحليل الكمي الدقيق في مجالات مثل علم الأمراض، وعلم الأحياء الخلوي، وأبحاث السرطان.³³
- تحليل أورام الدماغ (**Brain Tumor Analysis**): تُستخدم الخوارزمية بشكل فعال في تقسيم وتحديد حدود الأورام الدماغية، مثل الورم الأرومي الدبقي (Glioblastoma Multiforme)، من صور الرنين المغناطيسي (MRI). يساعد التقسيم الدقيق في تقييم حجم الورم، وتخطيط الجراحة أو العلاج الإشعاعي، ومراقبة استجابة المريض للعلاج.¹⁸
- تقسيم الأنسجة (**Tissue Segmentation**): في علم الأعصاب، تُستخدم الخوارزمية للمساعدة في فصل أنواع الأنسجة المختلفة في الدماغ، مثل التمييز بين المادة الرمادية والمادة البيضاء، وهو أمر بالغ الأهمية لدراسة بنية الدماغ ووظيفته في الصحة والمرض.¹⁷

في هذه التطبيقات الطبية، غالبًا ما يتم دمج Watershed مع تقنيات أخرى للتغلب على التحديات الشائعة مثل الضوضاء العالية والتباين المنخفض في الصور. على سبيل المثال، يمكن استخدام تقنيات المعالجة المورفولوجية المتقدمة لتنقية صورة التدرج، أو دمجها مع خوارزميات التجميع مثل Fuzzy C-Means لتحسين دقة العلامات.¹⁸ وفي الآونة الأخيرة، يتم استخدامها كخطوة تالية بعد التقسيم الأولي بواسطة الشبكات العصبونية التلافيفية (CNNs) لفصل المثيلات الفردية للخلايا أو الأورام التي تم تحديدها بواسطة الشبكة.³⁶

6.2 الزراعة وعلوم النبات (Agriculture and Plant Science)

في الزراعة الحديثة، تلعب معالجة الصور دورًا متزايد الأهمية في أتمتة المهام التي كانت تتطلب عمالة كثيفة.

- عد البذور والحبوب (**Seed and Grain Counting**): يعد العد الدقيق للبذور أمرًا ضروريًا لتقييم معدلات الإنبات، ومراقبة جودة البذور، وإدارة المخزون. غالبًا ما تكون البذور في الصور متلاصقة أو متداخلة. توفر خوارزمية Watershed طريقة قوية لفصل هذه البذور الفردية، مما يسمح بالعد الآلي السريع والدقيق.³⁷
- استخلاص حدود الأراضي الزراعية (**Cultivated Land Boundary Extraction**): يمكن تطبيق الخوارزمية على صور الأقمار الصناعية عالية الدقة أو صور الطائرات بدون طيار لتحديد ورسم الحدود الدقيقة للحقول الزراعية. هذه المعلومات حيوية للزراعة الدقيقة، ومراقبة المحاصيل، والتخطيط لاستخدام الأراضي.⁴¹

6.3 تطبيقات صناعية وغيرها

تمتد فائدة الخوارزمية إلى ما هو أبعد من العلوم البيولوجية.

- فحص المواد (**Materials Science**) في علم المعادن، يتم تحليل البنية المجهرية للمواد لفهم خصائصها. تُستخدم خوارزمية Watershed لتقسيم صور حبيبات الفولاذ أو السبائك الأخرى. يتيح فصل الحبيبات الفردية قياس حجمها وشكلها وتوزيعها، وهي عوامل تؤثر بشكل مباشر على صلابة المادة وقوتها ومتانتها.⁴
- تحليل الأجسام الفلكية (**Astronomy**) يمكن أن تكون صور المجرات والنجوم والميزات الفلكية الأخرى منخفضة التباين وصاخبة. يمكن تكييف خوارزمية Watershed للمساعدة في تقسيم هذه الصور، وفصل النجوم المتجاورة أو تحديد الهياكل داخل السدم والمجرات.⁴²

عند النظر إلى هذه التطبيقات المتنوعة - من خلايا الدم إلى بذور الذرة وحبيبات الفولاذ - يظهر نمط مشترك قوي. القوة الأساسية لخوارزمية Watershed ليست في التقسيم الدلالي العام (مثل العثور على "قطعة" في صورة)، بل في مهمة فرعية محددة للغاية: تقسيم المثيلات (**instance segmentation**) للكائنات المتكثلة ذات الشكل شبه المحدب. إنها تتألق عندما يكون لديك مجموعة من العناصر المتشابهة التي تتلامس أو تتداخل، وتحتاج إلى عدها أو تحليلها بشكل فردي. هذا التركيز المتخصص يفسر سبب بقاء خوارزمية ذات صلة وأهمية حتى في عصر التعلم العميق، لأنها تحل هذه المشكلة المحددة والشائعة بفعالية كبيرة، وغالبًا ما تُستخدم كخطوة تنقية بعد الكشف الأولي القائم على التعلم العميق.

القسم السابع: تحليل مقارن: Watershed مقابل تقنيات التقسيم الأخرى

لوضع خوارزمية Watershed في سياقها الصحيح، من الضروري مقارنتها بتقنيات تقسيم الصور الأخرى الشائعة. كل تقنية لها مبادئها الأساسية ونقاط قوتها وضعفها، مما يجعلها مناسبة لأنواع مختلفة من المشاكل. سيعقد هذا القسم مقارنة بين Watershed وكل من تجميع K-Means وكشف الحواف Canny.

7.1 Watershed مقابل تجميع K-Means

- المبدأ الأساسي: هناك اختلاف جوهري في كيفية "رؤية" كل خوارزمية للصورة.
- **Watershed:** هو نهج قائم على المنطقة والاتصال المكاني (**region-based**). تبدأ من "بذور" وتنمو المناطق للخارج، مع الأخذ في الاعتبار تجاوز البكسلات. البكسلات البعيدة عن بعضها البعض لا يمكن أن تكون جزءًا من نفس المنطقة الأولية.⁴³
- **K-Means:** هو نهج تجميع قائم على خصائص البكسل (**pixel-based clustering**). يقوم بتجميع البكسلات بناءً على تشابه خصائصها (عادةً اللون أو الكثافة) بغض النظر عن موقعها في الصورة. يمكن أن ينتمي بكسلان في طرفي نقيض من الصورة إلى نفس المجموعة إذا كان لهما نفس اللون.⁶
- نقاط القوة والضعف:
- **K-Means:** قوته تكمن في بساطته وسرعته في تجميع المناطق ذات الألوان المتشابهة، مما يجعله مثاليًا لتقليل عدد الألوان في الصورة (quantization) أو التقسيم الخام للمشاهد. ومع ذلك، فإنه لا يضمن أن تكون المجموعات الناتجة متصلة مكانيًا، وغالبًا ما ينتج "جزرًا" صغيرة من البكسلات المصنفة بشكل خاطئ بسبب الضوضاء. كما أنه يتطلب تحديد عدد

المجموعات (K) مسبقًا.⁶

- **Watershed:** قوته الرئيسية هي أنه يضمن دائمًا إنتاج مناطق مغلقة ومتصلة، مع حدود واضحة.⁴⁶ هذا يجعله متفوقًا بشكل كبير في فصل الكائنات المتلامسة التي قد يكون لها نفس اللون أو الكثافة، وهي مشكلة يفشل فيها K-Means تمامًا. ومع ذلك، فإن شكله التقليدي يعاني من التقسيم المفرط، ويعتمد شكله الموجه بالعلامات بشكل كبير على جودة العلامات الأولية.
- التكمال: في بعض الحالات، يمكن استخدام الخوارزميتين معًا. يمكن تطبيق K-Means أولاً لتقليل تعقيد الصورة وإنشاء تقسيم أولي. يمكن بعد ذلك استخدام نتائج هذا التقسيم للمساعدة في إنشاء علامات أكثر دقة لخوارزمية Watershed، مما يجمع بين قوة كلتا الطريقتين.⁴⁵

7.2 Watershed مقابل كشف الحواف (Canny Edge Detection)

- الوظيفة الأساسية: من المهم إدراك أن هاتين التقنيتين تخدمان أغراضًا مختلفة جوهريًا ولا تعتبران بدائل مباشرة لبعضهما البعض.
- **Canny:** هو كاشف حواف ((edge detector. هدفه هو تحديد البكسلات التي تشكل حوافًا في الصورة. المخرجات هي صورة ثنائية تحتوي على خطوط رفيعة تمثل هذه الحواف.⁴⁷
- **Watershed:** هي خوارزمية تقسيم ((segmentation algorithm. هدفها هو تقسيم الصورة بأكملها إلى مناطق منفصلة. المخرجات هي صورة مُسمّاة (labeled image) حيث تنتمي كل بكسل إلى منطقة معينة.⁴⁷
- العلاقة والقيود:
- لا ينتج Canny مناطق مغلقة. غالبًا ما تكون الحواف التي يكتشفها متقطعة أو غير مكتملة، مما يجعل من الصعب استخدامها مباشرة لاستخلاص كائنات كاملة. في المقابل، تضمن Watershed دائمًا حدودًا مغلقة.⁴⁶
- العلاقة بينهما هي علاقة اعتماد. تعتمد خوارزمية Watershed (عند تطبيقها على صورة التدرج) بشكل مباشر على جودة "الحواف" المكتشفة في تلك الصورة. بمعنى آخر، تعتمد جودة تقسيم Watershed على جودة "كشف الحواف" الضمني الذي يحدث عند حساب صورة التدرج. إذا كانت الحواف في صورة التدرج ضعيفة أو صاخبة، فستكون نتيجة Watershed ضعيفة بالمثل.⁴⁸ لذلك، يمكن اعتبار Canny أداة متخصصة في مهمة واحدة (إيجاد الحواف)، بينما تستخدم Watershed هذه المعلومات (أو ما شابهها) لإنجاز مهمة أكثر تعقيدًا (إنشاء مناطق).

جدول 2: مقارنة شاملة لتقنيات تقسيم الصور

يقدم هذا الجدول إطارًا لاتخاذ القرار، مما يساعد الممارسين على اختيار الأداة الأنسب لمشكلة التقسيم التي يواجهونها.

التقنية (Technique)	المبدأ الأساسي (Core Principle)	المخرجات (Output)	نقاط القوة (Strengths)	نقاط الضعف (Weaknesses)	حالة الاستخدام المثلى (Ideal Use Case)
------------------------	------------------------------------	----------------------	---------------------------	----------------------------	---

Watershed الموجه بالعلامات	نمو المناطق من علامات محددة مسبقاً بناءً على طبوغرافيا التدرج.	مصفوفة تسميات بمناطق مغلقة ومتصلة. الحدود تُعطى القيمة -1.	يضمن حدوداً مغلقة. ممتاز لفصل الكائنات المتلامسة. مرن للغاية.	يعتمد بشدة على جودة العلامات. يمكن أن يكون حساساً للمعطيات في المعالجة المسبقة.	تقسيم المثيلات للخلايا، البذور، أو أي كائنات متكتلة.
K- Means	تجميع البكسلات في K مجموعة بناءً على تشابه خصائصها (مثل اللون).	مصفوفة تسميات. المناطق الناتجة ليست بالضرورة متصلة مكانياً.	بسيط وسريع حسابياً. جيد للتقسيم القائم على اللون وتقليل الألوان.	يتطلب تحديد عدد المجموعات (K) مسبقاً. حساس للقيم المتطرفة. لا يراعي الاتصال المكاني.	تقسيم المشاهد حسب اللون (سماء، عشب، ماء). تقليل لوحة الألوان في الصور.
Canny كشف الحواف	كشف التغيرات الحادة في كثافة البكسل (التدرجات العالية).	صورة ثنائية تحتوي على خطوط رفيعة تمثل الحواف.	دقيق جداً في تحديد مواقع الحواف. معدل خطأ منخفض ومناعة جيدة ضد الضوضاء.	لا ينتج مناطق مغلقة (الحواف قد تكون متقطعة). ليس خوارزمية تقسيم بحد ذاتها.	استخلاص ملامح الكائنات. خطوة أولية لخوارزميات أخرى مثل التعرف على الأنماط.

القسم الثامن: استنتاجات وتوصيات

بعد التحليل المفصل لنظرية وتطبيق خوارزمية Watershed، يمكن استخلاص مجموعة من الاستنتاجات والتوصيات العملية للمطورين والباحثين في مجال رؤية الحاسوب ومعالجة الصور.

8.1 ملخص شامل

تُظهر هذه المراجعة أن خوارزمية Watershed، على الرغم من بساطة تشبيهها الطبوغرافي، هي أداة تقسيم قوية ومتعددة الاستخدامات بشكل ملحوظ، خاصة عند تطبيقها في شكلها الموجه بالعلامات.¹⁴ إن مفتاح نجاحها لا يكمن في الاستدعاء النهائي لدالة

cv2.watershed)، بل في خط أنابيب المعالجة المسبقة الدقيق والمدرّوس الذي يسبقها. إن القدرة على تحويل مشكلة تقسيم معقدة إلى سلسلة من العمليات المنطقية (العتبة، التنظيف المورفولوجي، تحويل المسافة، وتحديد المكونات المتصلة) هي التي تطلق العنان للإمكانات الحقيقية لهذه التقنية.¹⁴ لقد أثبتت الخوارزمية أنها ليست مجرد مفهوم أكاديمي، بل هي حل عملي لمشكلة متكررة ومهمة في العديد من المجالات العلمية والصناعية.

8.2 نقاط القوة والضعف الرئيسية

- نقاط القوة:
 - فصل الكائنات المتلامسة: تكمن القوة الأساسية والفريدة لخوارزمية Watershed في قدرتها التي لا مثيل لها على فصل الكائنات المتكتلة والمتداخلة، وهي مشكلة تواجهها العديد من تقنيات التقسيم الأخرى.²⁰
 - ضمان الحدود المغلقة: على عكس كاشفات الحواف التي قد تنتج خطوطاً منقطعة، تضمن خوارزمية Watershed دائماً أن تكون المناطق الناتجة مغلقة تماماً، مما يجعلها مثالية للمهام التي تتطلب استخلاص كائنات كاملة للقياس أو التحليل.⁴⁶
- نقاط الضعف:
 - الاعتماد على العلامات: إنها نعمة ونقمة في آن واحد. تعتمد جودة النتيجة النهائية بشكل كلي على دقة العلامات الأولية. إذا كانت العلامات غير دقيقة (على سبيل المثال، علامة واحدة تغطي كائنين، أو عدم وجود علامة لكائن ما)، فستكون نتيجة التقسيم خاطئة حتماً.
 - الحساسية للمعلومات: يتطلب خط أنابيب المعالجة المسبقة ضبطاً دقيقاً لبعض المعلومات، مثل عدد التكرارات في العمليات المورفولوجية أو نسبة العتبة المطبقة على خريطة المسافة. قد تحتاج هذه المعلومات إلى تعديل لتناسب أنواعاً مختلفة من الصور أو ظروف الإضاءة.

8.3 توصيات عملية للممارسين

بناءً على هذا التحليل، يمكن تقديم التوصيات التالية:

- متى تستخدمها: يجب أن تكون خوارزمية Watershed الموجهة بالعلامات هي الخيار الأول عند مواجهة مشكلة "تقسيم المثيلات" (instance segmentation) لكائنات متكتلة. إذا كان هدفك هو عد الخلايا في طبق بترّي، أو البذور على سطح، أو أي مجموعة من الكائنات المتشابهة والمتلامسة، فإن هذه الخوارزمية مصممة خصيصاً لهذه المهمة.²⁰
- كيف تستخدمها بفعالية: يجب أن ينصب التركيز الأساسي على تحسين خطوات إنشاء العلامات. لا تتردد في تجربة تقنيات مختلفة لتحديد "المقدمة المؤكدة" و"الخلفية المؤكدة". قد يتطلب الأمر استخدام عمليات مورفولوجية أكثر تعقيداً (مثل الفتح وإعادة البناء)، أو تعديل قيمة العتبة على خريطة المسافة، أو حتى استخدام طرق أخرى لتحديد العلامات. إن الاستثمار في تحسين العلامات هو أفضل طريقة لضمان نتائج تقسيم ممتازة.
- التكامل مع التقنيات الحديثة: في عصر التعلم العميق، لا ينبغي النظر إلى Watershed على أنها تقنية قديمة أو بديل للشبكات العصبونية، بل كأداة تكميلية قوية. يمكن بناء أنظمة هجينة متطورة حيث تقوم شبكة عصبونية تلافيفية (CNN) بأداء مهمة التقسيم الدلالي (semantic segmentation) - أي تحديد جميع البكسلات التي تنتمي إلى فئة "الخلايا". بعد ذلك، يمكن استخدام خوارزمية Watershed على مخرجات الشبكة لفصل "مثيلات" الخلايا الفردية المتلامسة. هذا النهج يجمع بين قدرة التعلم

المصادر التي تم الاقتباس منها

1. Analysis of the Variants of Watershed Algorithm as a Segmentation Technique in Image Processing - apiit, تم الوصول بتاريخ سبتمبر, 28, 2025, <https://www.apiit.edu.in/downloads/all%20chapters/CHAPTER-97.pdf>
2. University of Groningen The Watershed Transform Roerdink, Jos B.T.M.; Meijster, Arnold, تم الوصول بتاريخ سبتمبر, 28, 2025, <https://research.rug.nl/files/127130790/parwshed.pdf>
3. Overview of the watershed algorithm - YouTube, تم الوصول بتاريخ سبتمبر, 28, 2025, <https://www.youtube.com/watch?v=WQpXS9gBEu8>
4. The Watershed Transform: Strategies for Image Segmentation - MATLAB & Simulink, تم الوصول بتاريخ سبتمبر, 28, 2025, <https://www.mathworks.com/company/technical-articles/the-watershed-transform-strategies-for-image-segmentation.html>
5. Marker-Controlled Watershed Segmentation - MATLAB & Simulink Example - MathWorks, تم الوصول بتاريخ سبتمبر, 28, 2025, <https://www.mathworks.com/help/images/marker-controlled-watershed-segmentation.html>
6. Clustering and Segmentation | by Amit Yadav - Medium, تم الوصول بتاريخ سبتمبر, 28, 2025, <https://medium.com/@amit25173/clustering-and-segmentation-49086a4eabd5>
7. Watershed (image processing) - Wikipedia, تم الوصول بتاريخ سبتمبر, 28, 2025, [https://en.wikipedia.org/wiki/Watershed_\(image_processing\)](https://en.wikipedia.org/wiki/Watershed_(image_processing))
8. On the Regularization of the Watershed Transform - ResearchGate, تم الوصول بتاريخ سبتمبر, 28, 2025, https://www.researchgate.net/publication/228854556_On_the_Regularization_of_the_Watershed_Transform
9. Markers for watershed transform — skimage 0.25.2 documentation, تم الوصول بتاريخ سبتمبر, 28, 2025, https://scikit-image.org/docs/0.25.x/auto_examples/segmentation/plot_marked_watershed.html
10. (PDF) The Watershed Transform: Definitions, Algorithms and Parallelization Strategies, تم الوصول بتاريخ سبتمبر, 28, 2025, https://www.researchgate.net/publication/202232994_The_Watershed_Transform_Definitions_Algorithms_and_Parallelization_Strategies
11. Exploring Image Segmentation Techniques: Watershed Algorithm using OpenCV - Medium, تم الوصول بتاريخ سبتمبر, 28, 2025, <https://medium.com/@jaskaranbhatia/exploring-image-segmentation-techniques-watershed-algorithm-using-opencv-9f73d2bc7c5a>
12. Marker-Controlled Watershed for Segmentation of Images | Encyclopedia MDPI, تم الوصول بتاريخ سبتمبر, 28, 2025, <https://encyclopedia.pub/entry/24796>

13. An Overview of Watershed Algorithm Implementations in Open Source Libraries - MDPI, تم الوصول بتاريخ سبتمبر 28, 2025، <https://www.mdpi.com/2313-433X/4/10/123>
14. Image Segmentation with Watershed Algorithm - OpenCV Documentation, تم الوصول بتاريخ سبتمبر 28, 2025، https://docs.opencv.org/4.x/d3/db4/tutorial_py_watershed.html
15. Lung Segmentation by Marker-Controlled Watershed - Kaggle, تم الوصول بتاريخ سبتمبر 28, 2025، <https://www.kaggle.com/code/aadhavvignesh/lung-segmentation-by-marker-controlled-watershed>
16. 3D Clumped Cell Segmentation Using Curvature Based Seeded Watershed, تم الوصول بتاريخ سبتمبر 28, 2025، https://artscimedia.case.edu/wp-content/uploads/sites/166/2020/05/14170335/2016_MDPI_Imaging_WatershedSeg.pdf
17. Improved Watershed Transform for Medical Image Segmentation Using Prior Information, تم الوصول بتاريخ سبتمبر 28, 2025، https://www.researchgate.net/publication/8619372_Improved_Watershed_Transform_for_Medical_Image_Segmentation_Using_Prior_Information
18. Marker-controlled watershed algorithm and fuzzy C-means clustering machine learning: automated segmentation of glioblastoma from MRI images in a case series, تم الوصول بتاريخ سبتمبر 28, 2025، <https://pmc.ncbi.nlm.nih.gov/articles/PMC10923355/>
19. A Review of Watershed Implementations for Segmentation of ..., تم الوصول بتاريخ سبتمبر 28, 2025، <https://pmc.ncbi.nlm.nih.gov/articles/PMC9146301/>
20. Image Segmentation with Watershed Algorithm - OpenCV Python - GeeksforGeeks, تم الوصول بتاريخ سبتمبر 28, 2025، <https://www.geeksforgeeks.org/computer-vision/image-segmentation-with-watershed-algorithm-opencv-python/>
21. Watershed Segmentation Algorithm in Image Processing - Aegis Softtech, تم الوصول بتاريخ سبتمبر 28, 2025، <https://www.aegissofttech.com/articles/watershed-algorithm-and-limitations.html>
22. Opencv - Watershed's algorithm for image segmentation - Meccanismo Complesso, تم الوصول بتاريخ سبتمبر 28, 2025، <https://www.meccanismocomplesso.org/en/opencv-watersheds-algorithm-for-image-segmentation/>
23. Distance transformation in image - Python OpenCV - GeeksforGeeks, تم الوصول بتاريخ سبتمبر 28, 2025، <https://www.geeksforgeeks.org/python/distance-transformation-in-image-python-opencv/>
24. Python OpenCV - distanceTransform() Function - GeeksforGeeks, تم الوصول بتاريخ سبتمبر 28, 2025، <https://www.geeksforgeeks.org/python/python-opencv-distancetransform-function/>
25. Watershed OpenCV - PyImageSearch, تم الوصول بتاريخ سبتمبر 28, 2025، <https://pyimagesearch.com/2015/11/02/watershed-opencv/>
26. Connected Components Labeling Algorithm and its Computer Vision Applications - Medium, تم الوصول بتاريخ سبتمبر 28, 2025،

- <https://medium.com/@bikashojha904/connected-components-labeling-algorithm-and-its-computer-vision-applications-4d7ddd81cd1f>
27. OpenCV Connected Component Labeling and Analysis - PyImageSearch, تم الوصول بتاريخ سبتمبر 28, 2025، <https://pyimagesearch.com/2021/02/22/opencv-connected-component-labeling-and-analysis/>
 28. How to use OpenCV's connectedComponentsWithStats in Python? - Stack Overflow, تم الوصول بتاريخ سبتمبر 28, 2025، <https://stackoverflow.com/questions/35854197/how-to-use-opencvs-connectedcomponentswithstats-in-python>
 29. Distance Transform - PlantCV - Read the Docs, تم الوصول بتاريخ سبتمبر 28, 2025، https://plantcv.readthedocs.io/en/stable/distance_transform/
 30. Image Transformations Operations using OpenCV - DataFlair, تم الوصول بتاريخ سبتمبر 28, 2025، <https://data-flair.training/blogs/image-transformations-operations-using-opencv/>
 31. Python OpenCV - Connected Component Labeling and Analysis - GeeksforGeeks, تم الوصول بتاريخ سبتمبر 28, 2025، <https://www.geeksforgeeks.org/machine-learning/python-opencv-connected-component-labeling-and-analysis/>
 32. Image Segmentation with Distance Transform and Watershed Algorithm - OpenCV Documentation, تم الوصول بتاريخ سبتمبر 28, 2025، https://docs.opencv.org/4.x/d2/dbd/tutorial_distance_transform.html
 33. Watershed Separation - ImageJ Wiki, تم الوصول بتاريخ سبتمبر 28, 2025، <https://imagej.net/imaging/watershed>
 34. ML Guide on Cell Segmentation Using Watershed Algorithm - Labellerr, تم الوصول بتاريخ سبتمبر 28, 2025، <https://www.labellerr.com/blog/ml-guide-on-cell-segmentation-using-deep-learning/>
 35. Watershed Cell Segmentation - Kaggle, تم الوصول بتاريخ سبتمبر 28, 2025، <https://www.kaggle.com/code/eatmygoose/watershed-cell-segmentation>
 36. Watershed Algorithm for Medical Image Segmentation Based on Morphology and Total Variation Model | International Journal of Pattern Recognition and Artificial Intelligence, تم الوصول بتاريخ سبتمبر 28, 2025، <https://www.worldscientific.com/doi/full/10.1142/S0218001419540193>
 37. Automated seed counting using image processing and deep learning - PMC, تم الوصول بتاريخ سبتمبر 28, 2025، <https://pmc.ncbi.nlm.nih.gov/articles/PMC12426890/>
 38. Design and test of 1000-grain weight rapid measuring instrument based on machine vision., تم الوصول بتاريخ سبتمبر 28, 2025، <https://www.cabidigitallibrary.org/doi/abs/10.5555/20220120731>
 39. Corn Seed Defect Detection Based on Watershed Algorithm and Two-Pathway Convolutional Neural Networks - Frontiers, تم الوصول بتاريخ سبتمبر 28, 2025، <https://www.frontiersin.org/journals/plant-science/articles/10.3389/fpls.2022.730190/full>
 40. Corn Seed Defect Detection Based on Watershed Algorithm and Two-Pathway Convolutional Neural Networks - PubMed Central, تم الوصول بتاريخ سبتمبر 28, 2025،

- <https://pmc.ncbi.nlm.nih.gov/articles/PMC8905238/>
41. A Watershed-Segmentation-Based Improved Algorithm for Extracting Cultivated Land Boundaries - MDPI, تم الوصول بتاريخ سبتمبر 28, 2025،
<https://www.mdpi.com/2072-4292/13/5/939>
 42. Watershed segmented image using distance transform with canny edge detector. - ResearchGate, تم الوصول بتاريخ سبتمبر 28, 2025،
https://www.researchgate.net/figure/Watershed-segmented-image-using-distance-transform-with-canny-edge-detector_fig8_258651893
 43. Image Segmentation Methods: What Is the Best Way to Organize Them? help - Reddit, تم الوصول بتاريخ سبتمبر 28, 2025،
https://www.reddit.com/r/computervision/comments/1ickewg/image_segmentation_methods_what_is_the_best_way/
 44. [Python-CV2] Image Segmentation : Canny Edges, Watershed, and K-Means Methods, تم الوصول بتاريخ سبتمبر 28, 2025، <https://dev.to/jarvissan22/python-cv2-image-segmentation-canny-edges-watershed-and-k-means-methods-18l0>
 45. Image Segmentation with Clustering K-Means and Watershed Transform - ResearchGate, تم الوصول بتاريخ سبتمبر 28, 2025،
https://www.researchgate.net/publication/232652187_Image_Segmentation_with_Clustering_K-Means_and_Watershed_Transform
 46. View of IMAGE SEGMENTATION: A WATERSHED TRANSFORMATION ALGORITHM, تم الوصول بتاريخ سبتمبر 28, 2025، <https://www.ias-iss.org/ojs/IAS/article/view/852/755>
 47. Comprehensive Guide to Edge Detection Algorithms - GeeksforGeeks, تم الوصول بتاريخ سبتمبر 28, 2025، <https://www.geeksforgeeks.org/computer-vision/comprehensive-guide-to-edge-detection-algorithms/>
 48. What are the limitations of Watershed Segmentation Algorithm?, تم الوصول بتاريخ سبتمبر 28, 2025، <https://dsp.stackexchange.com/questions/58359/what-are-the-limitations-of-watershed-segmentation-algorithm>
 49. Comparative Analysis of Image Segmentation using Edge-Region Based Technique and Watershed Transform - ijltomas, تم الوصول بتاريخ سبتمبر 28, 2025،
<https://www.ijltomas.in/DigitalLibrary/Vol.7Issue5/01-04.pdf>